

14, 15 Temporal Difference learning

Yun Seong Cho

목차


1. AB example

2. Cliff walking

3. Variation of method







AB example for unknown MDP with a batch of 8 episodes.

 ${A, 0, B, 0}, {B, 1}, {B, 1}, {B, 1}, {B, 1}, {B, 1}, {B, 1}, {B, 0}$



 ${A, 0, B, 0}, {B, 1}, {B, 1}, {B, 1}, {B, 1}, {B, 1}, {B, 1}, {B, 0}$

What is the best values for the estimates V(A) and V(B)? $(\gamma = 1)$



$${A, 0, B, 0}, {B, 1}, {B, 1}, {B, 1}, {B, 1}, {B, 1}, {B, 1}, {B, 0}$$

What is the best values for the estimates V(A) and V(B)? $(\gamma = 1)$

MC
$$V(A) \leftarrow V(A) + \alpha \left[\underline{R_{t+1} + \gamma V(B)} - V(A) \right]$$

TD
$$V(A) \leftarrow V(A) + \alpha \left[G_t - V(A) \right]$$



$$\{A, 0, B, 0\}, (B, 1), (B, 1), (B, 1), (B, 1), (B, 1), (B, 1), (B, 0)$$

What is the best values for the estimates


$$V(B)$$
? ($\gamma = 1$)



$$\{A, 0, B, 0\}, (B, 1), (B, 1), (B, 1), (B, 1), (B, 1), (B, 1), (B, 0)\}$$

What is the best values for the estimates

$$V(B)$$
? ($\gamma = 1$)



MC 시작점(SO)가 B이면 에피소드가 끝날 때까지 진행하면 expected return = 0.75

TD 시작점(S0)가 B이면 한번 액션을 취하고 얻는 expected reward + γ x estimate = 0.75

$$\longrightarrow MC, TD : V(B) = 0.75$$




$$(A, 0, B, 0), \{B, 1\}, \{B, 1\}, \{B, 1\}, \{B, 1\}, \{B, 1\}, \{B, 1\}, \{B, 0\}$$

What is the best values for the estimates V(A) ($\gamma = 1$)



$$(A, 0, B, 0), \{B, 1\}, \{B, 1\}, \{B, 1\}, \{B, 1\}, \{B, 1\}, \{B, 1\}, \{B, 0\}$$

What is the best values for the estimates V(A) ($\gamma = 1$)



MC 시작점(SO)가 A이면 에피소드가 끝날 때까지 진행하면 expected return = 0

TD 시작점(S0)가 A0I면 한번 액션을 취하고 얻는 expected reward + γ x estimate = 0.75

$$\longrightarrow$$
 MC : V(A) = 0 , TD : V(A) = 0.75



 ${A, 0, B, 0}, {B, 1}, {B, 1}, {B, 1}, {B, 1}, {B, 1}, {B, 1}, {B, 0}$

What is the best values for the estimates V(A) ($\gamma = 1$)

$$V(A) = 0$$

$$V(B) = 0.75$$


$$V(A) = 0.75$$

$$V(B) = 0.75$$

MC 방법이 sample에 더 의존하고, TD 방법은 estimate을 사용하여 sample의 future data error에 저항이 있다.
















Sarsa vs Q-learning




Sarsa: On-Policy TD Prediction

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha \left[R_{t+1} + \gamma Q(S_{t+1}, A_{t+1}) - Q(S_t, A_t) \right]$$

Q-learning: Off-Policy TD Prediction (Watkins 1989) $Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha \left[R_{t+1} + \gamma \max_{a} Q(S_{t+1}, a) - Q(S_t, A_t) \right]$

$$\varepsilon - greedy(Q) = \begin{cases} 1 - \varepsilon + \frac{\varepsilon}{m} & \text{, } a: highest \ Q \\ \frac{\varepsilon}{m} & \text{, } otherwise \end{cases}$$
 Safer path




Sarsa: On-Policy TD Prediction $Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha \left[R_{t+1} + \gamma Q(S_{t+1}, A_{t+1}) - Q(S_t, A_t) \right]$


' target policy가 arepsilon - greedy(Q) 방식을 사용하기 때문에 절벽 아래로 떨어질 확률을 고려 '

Q-learning: Off-Policy TD Prediction (Watkins 1989)
$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha \left[R_{t+1} + \gamma \max_{t} Q(S_{t+1}, a) - Q(S_t, A_t) \right]$$

'target policy가 $\max_a Q(S_{t+1},a)$ 방식을 사용하기 때문에 이익이 최대가 되는 방향만 고려 '











만약 arepsilon이 이에 가까워진다면, SARSA에서 다른 선택을 고려하지 않게 되고, 그로 인해 optimal path로 수렴









Variation of method



Expected Sarsa


$$\varepsilon - greedy(Q) = \begin{cases} 1 - \varepsilon + \frac{\varepsilon}{m} & \text{, } a : highest Q \\ \frac{\varepsilon}{m} & \text{, } otherwise \end{cases}$$

• Sarsa

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha \left[R_{t+1} + \gamma Q(S_{t+1}, A_{t+1}) - Q(S_t, A_t) \right]$$

• Q-learning


$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha \left[R_{t+1} + \gamma \max_{a} Q(S_{t+1}, a) - Q(S_t, A_t) \right]$$



Expected Sarsa

$$Q(S_{t}, A_{t}) \leftarrow Q(S_{t}, A_{t}) + \alpha \left[R_{t+1} + \gamma \mathbb{E}_{\pi} \left[Q(S_{t+1}, A_{t+1}) \mid S_{t+1} \right] - Q(S_{t}, A_{t}) \right]$$

$$\left(= Q(S_{t}, A_{t}) + \alpha \left[R_{t+1} + \gamma \sum_{t=1}^{\infty} \pi(a \mid S_{t+1}) Q(S_{t+1}, a) - Q(S_{t}, A_{t}) \right] \right)$$



기존 Sarsa는 비록 $\varepsilon-greedy(Q)$ 방식을 사용하였지만, 그 중에 하나의 액션에 대한 값을 target으로 정하게 된다. 이것을 보완하기 위하여 같은 policy에 대해서 expected sum을 한 값을 target으로 정해서 모든 액션을 고려할 수 있다.



Double Q-learning

기존 Q-learning은 PE 단계에서 maximization operation을 사용하기 때문에 실제 sampling 할 때와 비교했을 때 과대평가(overestimated) 되는 경향이 있습니다. 이것은 $q^*(s,a)$, 즉 optimal로 수렴하는데 시간이 더 걸린다.

이것을 보완하기 위해서는 maximization operation을 사용하되 너무 maximum Q값을 선택하지 않아야 한다. 이를 위해서 2개의 Q-table을 만들어서 서로가 서로의 target이 되어서 PE를 진행하는 방법이 있는데 이것을 Double Q-learning이라고 한다.

Q-learning
$$Q(S,A) \leftarrow Q(S,A) + \alpha \left[R + \gamma \max_{a} Q(S',a) - Q(S,A)\right]$$
 Double Q-learning
$$Q_1(S,A) \leftarrow Q_1(S,A) + \alpha \left[R + \gamma Q_2(S', \arg\max_{a} Q_1(S',a)) - Q_1(S,A)\right]$$

$$Q_2(S,A) \leftarrow Q_2(S,A) + \alpha \left[R + \gamma Q_1(S', \arg\max_{a} Q_2(S',a)) - Q_2(S,A)\right]$$

$TD(\lambda)$

$$G_t^{(1)} = R_{t+1} + \gamma V(S_{t+1})$$



$$G_t^{(n)}=R_{t+1}+\gamma R_{t+2}+\cdots+\gamma^{n-1}R_{t+n}+\gamma^n V(S_{t+n})$$
 더 많은 step까지 고려하고 싶다





$$G_t^{(\infty)} = R_{t+1} + \gamma R_{t+2} + \cdots + \gamma^{T-t-1} R_T$$



 $TD(\lambda)$

TD(n)
$$G_t^{(n)} = R_{t+1} + \gamma R_{t+2} + \cdots + \gamma^{n-1} R_{t+n} + \gamma^n V(S_{t+n})$$

n번째 리워드까지 더하는 것은 좋지만 TD(n)은 + + 1 번째부터 + + n - 1 번째 state은 참고하지 않는 문제점이 있다.

$$\begin{cases}
G_t^{(1)} = R_{t+1} + \gamma V(S_{t+1}) \\
G_t^{(n)} = R_{t+1} + \gamma R_{t+2} + \dots + \gamma^{n-1} R_{t+n} + \gamma^n V(S_{t+n}) \\
G_t^{(\infty)} = R_{t+1} + \gamma R_{t+2} + \dots + \gamma^{T-t-1} R_T
\end{cases}$$

모든 경우를 다 더해서 모든 state을 참고하자!

$$\longrightarrow G_t^{\lambda} = (1 - \lambda) \sum_{n=1}^{\infty} \lambda^{n-1} G_t^{(n)}$$



감사합니다

