# **REINFORCE**

Kihwan Lee

# **Contents**

1. REINFORCE

2. REINFORCE with baseline



## REINFORCE

#### # REINFORECE

- Q value값을 output으로 하는 DQN과 달리 > action값을 output으로 도출 : conti-action space
- Policy Gradient Thm을 통해 목적함수의 gradient를 계산하기 쉽게 표현 :  $\nabla_{\theta} J(\theta) = \nabla_{\theta} \mathbb{E}_{\pi_{\theta}} [r(\tau)] = \mathbb{E}_{\pi_{\theta}} [r(\tau) \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_{t} \mid s_{t})]$
- mini-batch M개의 trajectory의 샘플을 찾은 후에 평균으로 대체 : MCMC Sampling
- Total reward r(τ)를 discounted return Gt로 대체하여 앞으로 얻을 reward만 고려
  - => REINFORCE (Monte Carlo Policy Gradient)

#### Repeat $(1) \sim (3)$

- (1) Execute M trajectories (each starting in state s and executing (stochastic) policy  $\pi_{\theta}$ )
- (2) Approximate the gradient of the objective function  $J(\theta)$

$$g_{\theta} := \frac{1}{M} \sum_{i=1}^{M} \left( \sum_{t=0}^{T-1} G_t^{(i)} \nabla_{\theta} \log \pi_{\theta}(a_t^{(i)} | s_t^{(i)}) \right) \approx \nabla_{\theta} J(\theta)$$

(3) Update policy (network parameters) to maximize  $J(\theta)$ 


$$\theta := \theta + \alpha g_{\theta} \approx \theta + \alpha \nabla_{\theta} J(\theta)$$

# 2. REINFORCE with baseline

# **REINFORCE** with baseline

#### • 목**표**

- 1) 안정적인 학습을 위한 variance를 줄이기
- 2) 평균을 제대로 잡게 bias를 줄이기



#### Problem

Monte Carlo의 경우 data를 생성할 때, 즉 trajectory를 만들 때 (... St at rt+1 St+1 ...) 모든 곳에서 무작위성이 발생 (ε-greedy)


=> 이로 인한 variance가 너무 크다.

## **REINFORCE** with baseline

#### # REINFORECE with Baseline

앞에서 언급한 MC의 높은 variance 문제로 인해 기존 REINFORECE 목적함수에 baseline을 빼준다.

$$\nabla_{\theta} J(\theta) = \nabla_{\theta} \mathbb{E}_{\pi_{\theta}} [r(\tau)] = \mathbb{E}_{\pi_{\theta}} \left[ \sum_{t=0}^{T-1} \left( \underline{G_t - b(s_t)} \right) \underline{\nabla_{\theta} \log \pi_{\theta}(a_t \mid s_t)} \right]$$



- \* 고려해야 할 점 : b(st)를 빼줌으로 expectation이 바뀌어서는 안 된다. (bias 발생) => b(st) 은 action과 관계 없는 값이라면 다 적합!
- $\mathbb{E}_{\pi}\left[\sum_{t} b(s_{t}) \nabla \log \pi(a_{t} \mid s_{t})\right] = \int \sum_{t} \pi(a_{t} \mid s_{t}) b(s_{t}) \nabla \log \pi(a_{t} \mid s_{t}) d\tau = \int \sum_{t} b(s_{t}) \nabla \pi(a_{t} \mid s_{t}) d\tau = 0$ since  $\sum_{a_{t}} b(s_{t}) \nabla \pi(a_{t} \mid s_{t}) = b(s_{t}) \nabla \sum_{a_{t}} \pi(a_{t} \mid s_{t}) = b(s_{t}) \nabla 1 = 0.$
- \* Good baseline : the state-value of current state V(s) :  $V(s) = \mathbb{E}_{\pi_{\theta}}[G_t \mid S_t = s]$ .

=> Keeping the gradient unbiased

## **REINFORCE** with baseline

#### # REINFORECE with Baseline

기존 REINFORCE에서는 policy에 대한 network만 존재

=> 이제는 baseline으로 사용되는 State value function과 관련한 network가 추가적으로 필요

```
Initialize state-value V(s;\phi) and policy \pi(a \mid s;\theta) randomly Hyperparameters: stepsizes \alpha>0,\ \beta>0 for episode =1,M do Generate an episode s_0,a_0,r_1,s_1,\ldots,s_{T-1},a_{T-1},r_T, following \pi(\cdot \mid \cdot;\theta) for t=0,T-1 do G_t\leftarrow \text{return from step }t \delta\leftarrow G_t-V(s_t;\phi) \phi\leftarrow \phi+\beta\delta\nabla_\phi V(s_t;\phi) minimizing L(\phi)=\mathbb{E}_{\pi_\theta}\big[\sum_{t=0}^{T-1}\big(G_t-V(s_t;\phi)\big)^2\big] \theta\leftarrow \theta+\alpha\gamma^t\delta\nabla_\theta\log\pi(a_t\mid s_t;\theta) \nabla_\theta J(\theta)=\mathbb{E}_{\pi_\theta}\big[\sum_{t=0}^{T-1}\big(G_t-V(s_t;\phi)\big)^2\big] end end
```